Rapport TNL

Amaury JACOB-PIACENTINI Sharaine MALAVIJY

29 mars 2026

Table des matières

1 Introduction **2**

2 Analyse des données **2**
2.1 Classification de sentiments 2
2.1.1 Description du jeu de données 2
2.1.2 Analyse du jeu de données 2
2.2 Classification des discours de Présidents 2
2.2.1 Description du jeu de données 2
2.2.2 Analyse du jeu de données 3
2.3 Prétraitement des données 4
2.3.1 Description 4
2.3.2 Objectifs du prétraitement 4
2.3.3 Nettoyage du texte 4

3 Classification **6**
3.1 Méthodologie 6
3.2 Modèles testés 6
3.3 Résultats 6
3.4 Analyse 6

4 Conclusion **7**

1 Introduction

Le but de ce projet est de classifier des textes afin de pouvoir nous former aux divers outils de traitement du langage naturel. Pour cela, nous avons deux jeux de données différents : un jeu de données contenant des critiques de films, et un autre contenant des discours de Jaques Chirac et de François Mitterrand.
Nous avons divisé notre travail en plusieurs parties. Dans un premier temps, nous avons fait de l'analyse des données et du pré traitement des données. Ensuite nous avons pu commencer le travail de classification. Nous avons exploré plusieurs techniques de classification vu lors des TME et du cours.

2 Analyse des données

2.1 Classification de sentiments

2.1.1 Description du jeu de données

Ce jeu de données contient des critiques de films. C'est un jeu de données équilibré, nous avons 2000 critiques de films au total dont 1000 critiques positives et 1000 critiques négatives. Chaque critique de film est constituée de plusieurs phrases. Nous avons également les labels associés à chaque critique de film : 1 pour les critiques positives et 0 pour les critiques négatives.

2.1.2 Analyse du jeu de données

Dans un premier temps, nous avons calculer la taille du vocabulaire du jeu de données. Nous avons 39659 mots différents avant de faire un pré traitement des données.
Après calculer la taille du vocabulaire, il a fallu regarder la fréquence des mots dans le dataset.
Voici un exemple de la fréquence des mots dans le dataset :

Mot	Fréquence
the	76529
and	35576
of	34123
to	31937
is	25195

Table 1 – Mots les plus fréquents (0)

Comme attendu, avant toute forme de pré traitement, les mots les plus fréquents sont les stops words. Ils n'apportent pas d'information discriminante plus tard dans la partie prétraitement. ils seront supprimés.
Une meilleure façon de visualiser la fréquence des mots est d'utiliser un word cloud. Ainsi que la distribution de Zipf.

Il est aussi intéressant de regarder les mots les plus discriminants pour les critiques positives et négatives. Les mots les plus discriminants seront fait après le pré traitement des données.
Sur la distribution de Zipf on remarque que quelques mots sont très fréquents et que la grande majorité des mots sont peu fréquents.

2.2 Classification des discours de Présidents

2.2.1 Description du jeu de données

Ce jeu de données contient des discours de Jaques Chirac et de François Mitterrand. Ce jeu de données est largement plus complexe à traiter que le jeu de données de critiques de films car le jeux est largement plus désiquilibré. Nous avons 57413 phrases au total dont 49890 (86.90%) de Jaques Chirac et 7523 (13.10%) de François Mitterrand.

and
of the
in the
the film
to be
is a
but
on the
and the
in a
the movie
this film
with a
for the
as the
the most
to a
out of
that the
there i
the same
one of
that i
the first
to see
the character
from the
by the
this
it
film i
at the
or
from
of his
her
movie
story
movie
this
the
that
all
the
the
the

2.3 Prétraitement des données

2.3.1 Description

Le prétraitement des données est une des étapes les plus importantes dans ce projet. Nous avons plusieurs techniques différentes pour faire du prétraitement pour finalement arriver à une pipeline de prétraitement qui nous semble la plus adaptée pour nos jeux de données.

2.3.2 Objectifs du prétraitement

Dans un premier temps il a fallu faire un préprétraitement des données. Nous avons d'abord converti tous les mots en minuscules afin de ne pas avoir de doublons dans notre vocabulaire. Ensuite, nous avons supprimé les caractères spéciaux et les chiffres car ils n'apportent pas d'informations pertinentes pour la classification.
Nous avons aussi essayé de garder uniquement les premières lignes de chaque critique de film pour voir si cela pouvait améliorer les performances de nos modèles. Cependant, cela n'a pas eu d'impact significatif sur les performances de nos modèles.

2.3.3 Nettoyage du texte

La premières chose qui à été fait pour le nettoyage du texte a été de supprimer les majuscules. Ensuite, nous avons supprimé les caractères spéciaux et les chiffres. Nous avons aussi supprimé les stop words car ils n'apportent pas d'informations pertinentes pour la classification.
Pour le jeu de données des avis de films nous avons supprimé les mots les plus fréquents car ils sont très peu discriminants. Il à fallu aussi ajouté une liste de mots plus rares mais non discriminants.

Les plus fréquents n'apportent pas d'informations discriminantes c'est à dire qu'ils sont présents dans les critiques de films positives et négatives.

Pour le jeu de données des discours de présidents nous avons supprimé les stop words francais, nous avons aussi retiré les mots "français", "pays" et "qu" car ils sont très peu discriminants. Ce data set est beaucoup plus complexe à traiter que le précédent. vu qu'il est déséquilibré les Chirac est sur représenté sur les graphes

Il est intéressant de comparer les graphes de la répartition des mots positifs et négatifs avant et après le prétraitement des données.

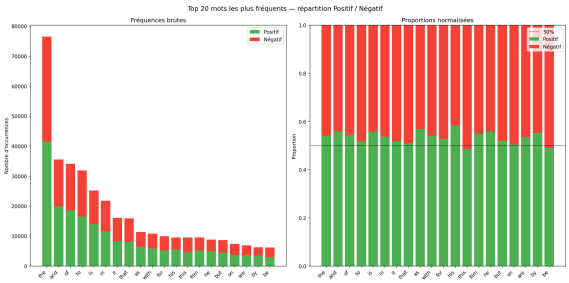

FIGURE 5 – *
fréquence des mots et caractère discriminant des mots dans les critiques de films avant prétraitement

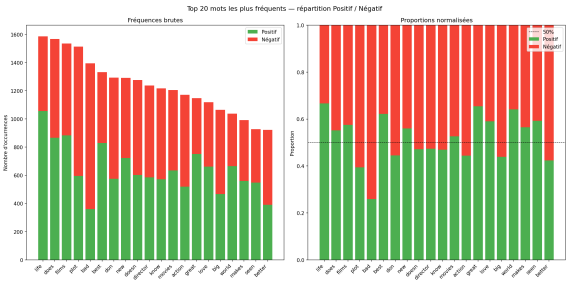

FIGURE 6 – *
fréquence des mots et caractère discriminant des mots dans les discours de présidents avant prétraitement

Comme on peut les voir sur les graphes après le prétraitement des données, les mots les plus fréquents on évidement changé mais sur tout nous pouvons remarquer que les mots sont bien plus discriminants qu'avant le prétraitement des données. Nous avons beaucoup plus de mots qui sont présents dans les critiques de films positives que dans les critiques de films négatives et inversement.

Il est aussi intéressant de regarder la courbe de Zipf après le prétraitement des données. Nous pouvons voir que la courbe de Zipf est beaucoup plus lisse après le prétraitement des données.

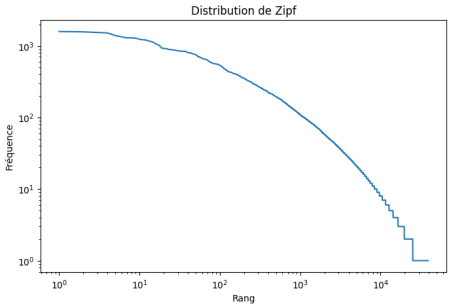

FIGURE 7 – *
Distribution de Zipf des critiques de films après prétraitement

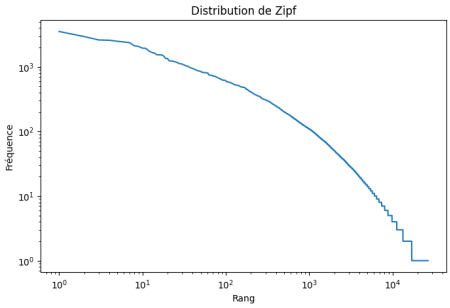

FIGURE 8 – *
Distribution de Zipf des discours de présidents après prétraitement

Sur les Figures 2 et 4 les courbes de zipf montrent que les corpus sont dominés par un petit nombre de mots très fréquents, tandis que la grande majorité des mots sont rares. Cependant, après le prétraitement des données, les courbes de Zipf deviennent plus lisses, ce qui indique que les mots les plus fréquents ont été supprimés et que les mots restants sont plus équilibrés en termes de fréquence.

Ce prétraitement des données est le premier que nous avons implémenté. Il ne donnait pas de résultats satisfaisants donc nous nous sommes dirigés vers la TF-IDF pour faire du prétraitement des données.

La TF-IDF (Term Frequency – Inverse Document Frequency) consiste à attribuer un poids à chaque mot en fonction de son importance dans un document et dans l'ensemble du corpus. La composante TF (Term Frequency) mesure la fréquence d'un mot dans un document, tandis que la composante IDF (Inverse Document Frequency) pénalise les mots apparaissant fréquemment dans de nombreux documents. Ainsi, un mot fréquent dans un document mais rare dans le corpus aura un poids élevé, ce qui le rend plus discriminant pour la classification.

Nous avons utilisé la TF-IDF de la librairie Scikit-learn, beaucoup de configurations on été testées et nous nous sommes arrêtés sur celle qui donnait les meilleurs résultats.

Pour le jeu de données des films, nous avons utilisé les paramètres `max_df = 1`, `min_df = 3` et `sublinear_tf = True`. Le paramètre `min_df = 3` permet de supprimer les mots apparaissant dans moins de trois documents, ce qui réduit le bruit lié aux mots très rares ou aux erreurs typographiques. Le paramètre `max_df = 1` signifie que nous ne filtrons pas explicitement les mots très fréquents, car la pondération TF-IDF se charge déjà de diminuer leur importance.

L'option `sublinear_tf = True` applique une transformation logarithmique sur la fréquence des mots, donnée par $1 + \log(\text{tf})$, ce qui permet de limiter l'influence des mots très fréquents dans un document et d'obtenir une représentation plus équilibrée.

Enfin, nous avons choisi de désactiver le prétraitement manuel (mise en minuscules, suppression des accents, etc.), car l'implémentation de Scikit-learn intègre déjà certaines étapes de normalisation, notamment la conversion en minuscules, et les résultats expérimentaux ont montré que ce prétraitement supplémentaire n'apportait pas d'amélioration significative des performances.

Nous pouvons visualiser les mots les plus discriminants pour les critiques de films positives et négatives après le prétraitement des données.

Pour les discours de présidents et le transformer nous avons appliqué des peu de prétraitement des données, mais nous avons mis des poids plus élevés pour les dicours de François Mitterrand pour compenser le déséquilibre des classes.

3 Classification

Dans cette section, nous présentons les différentes méthodes de classification testées sur nos jeux de données. Nous comparons leurs performances afin d'identifier les approches les plus efficaces pour chaque tâche.

3.1 Méthodologie

Nous utilisons une représentation TF-IDF avec des n-grammes (1,2). Les modèles sont évalués à l'aide d'une validation croisée (K-Fold) afin d'obtenir des résultats robustes.

Pour le jeu de données des films, nous utilisons une validation croisée à 5 plis, tandis que pour les discours politiques nous utilisons une validation croisée à 10 plis.

Les métriques utilisées sont :

— Accuracy
— F1-score
— Précision
— Rappel
— ROC-AUC (pour les discours)

3.2 Modèles testés

Nous avons expérimenté plusieurs modèles de classification :

— SVM linéaire (`LinearSVC`)
— Régression logistique
— Naive Bayes multinomial
— Transformers (BERT)

3.3 Résultats

Modèle	Accuracy	F1-score	Précision	Rappel
SVM	0.89	0.88	0.87	0.89
Logistic Regression	...	...	...	...
Naive Bayes	...	...	...	...
Transformers (BERT)	...	...	...	...

Table 3 – Résultats sur les critiques de films

3.4 Analyse

Le modèle SVM linéaire obtient les meilleures performances sur les deux jeux de données. Cela s'explique par sa capacité à gérer des données de grande dimension, comme les représentations TF-IDF.

Le Naive Bayes, bien que rapide, présente des performances inférieures, notamment en raison de son hypothèse d'indépendance entre les mots.

On remarque également que les performances sont plus faibles sur le jeu de données des discours politiques. Cela s'explique par le déséquilibre des classes et la complexité du langage utilisé.

Avec le transformers (BERT),

4 Conclusion

En conclusion, ce projet nous a permis d'explorer différentes techniques de prétraitement et de classification pour des tâches de NLP. Nous avons vu l'importance du prétraitement des données, notamment l'utilisation de la TF-IDF, pour améliorer les performances des modèles.